

Nom, prénom :

/10

*Durée : 15 minutes.**Dans les questions qui concernent le langage Python, le respect de la syntaxe (et des espaces) est pris en compte dans la notation. Les questions sont indépendantes.**Accès à python, au cours autorisé et à internet autorisé.*

Question 1 : Il vous est demandé **de renseigner le code** nécessaire pour répondre à chaque question. Un résultat numérique est attendu en plus du code à la question 3.

Le module numpy a été importé avec la commande : `import numpy as np`

1. Générer le vecteur Z avec 5000 points suivant la distribution gaussienne N(0,1)
[code]

```
Z = np.random.normal(size=5000)
```

2. Compter le nombre d'éléments de Z supérieurs à -1 et inférieurs à 1 ? [code]

```
sum(abs(Z) < 1)
```

3. Quelle est la proportion d'éléments de Z supérieurs à -1 et inférieurs à 1 ?
[code + valeurs]

```
sum(abs(Z) < 1) / len(Z)
```

Environ 68%

4. Expliquer les valeurs obtenues

Correspond à ce qu'on attend comme proportions pour une gaussienne à 1 sigma (~68,2%), ici sigma valant 1.

Question 2 : Le résultat de la résolution analytique pour les coefficients de la régression linéaire vue en cours est la suivante :

$$\hat{\theta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{cov(x, y)}{var(x)}$$

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}$$

$\hat{\theta}_0$ et $\hat{\theta}_1$ sont les coefficients que l'on souhaite estimer, tels que

$$\hat{y} = \hat{\theta}_0 + \hat{\theta}_1 x$$

\bar{x} et \bar{y} sont les moyennes respectives des vecteurs x et y .

La covariance et la variance sont définies par :

$$cov(x, y) = \frac{1}{N} * \sum (x_i - \bar{x})(y_i - \bar{y})$$

$$var(x) = \frac{1}{N} * \sum (x_i - \bar{x})^2$$

avec $N = len(x) - 1$

Nous allons vous demander de créer plusieurs fonctions pour calculer au final les paramètres $\hat{\theta}_0$ et $\hat{\theta}_1$ de façon analytique. **L'ordre des questions n'est pas aléatoire !**

- Dans ce qui suit, **x et y sont des listes de nombres de même taille.**
- **Vous n'avez pas accès à numpy.**

1/ Créer la fonction `moyenne(x)` retournant la moyenne de la liste x

```
def moyenne(x):
    return sum(x)/len(x)
```

2/ Créer la fonction `produit_scalaire(x, y)` permettant de retourner le résultat du produit scalaire de x et y

```
def produit_scalaire(x, y):
    return sum([i*j for i, j in zip(x, y)])
```

3/ Créer la fonction `covariance(x, y)` permettant de retourner le résultat du calcul de la covariance, définie plus haut, en utilisant la fonction `produit_scalaire()`

```
def variance(x):
    return covariance(x, x)
```

4/ Créer la fonction `variance(x)` permettant de retourner le résultat du calcul de la variance, définie plus haut

```
def covariance(x, y):
    N = len(x)-1
    return 1/N*produit_scalaire(x-moyenne(x), y-moyenne(y))
```

5/ Créer la fonction `linear_parameters(x, y)` permettant de retourner les résultats de l'estimation des paramètres $\hat{\theta}_0$ et $\hat{\theta}_1$, à partir des équations définies plus haut.

```
def linear_parameters(x, y):
    theta_1 = covariance(x, y) / variance(x)
    theta_0 = moyenne(y) - theta_1*moyenne(x)
    return theta_0, theta_1
```